دانشگاه ارومیه - دانشکده فنی و مهندسی
گروه مهندسی کامپیوتر

گزارش تمرین اول: پیش‌بینی قیمت طلا با مدل‌های رگرسیون خطی و ریج (Ridge)

نام دانشجو: متین سجودی | شماره دانشجویی: 14014421025
استاد درس: دکتر صالح یوسفی | پاییز ۱۴۰۵

---

۱. مقدمه و بیان مسئله

در این تمرین هدف اصلی، بررسی و ارزیابی توانایی مدل‌های رگرسیون پایه در پیش‌بینی قیمت بسته شدن (Close) روز بعد طلا بر اساس متغیرهای معاملاتی روز جاری است. مجموعه داده مورد استفاده مربوط به صندوق طلای SPDR (نماد GLD) در بازه زمانی سال‌های ۲۰۱۸ تا انتهای ۲۰۲۴ (حدود ۷ سال داده روزانه بازار) می‌باشد. در این پروژه دو مدل رگرسیون خطی معمولی (Linear Regression) و رگرسیون ریج با جریمه لایه دوم (Ridge Regression) پیاده‌سازی شده و نتایج آنها با معیارهای استاندارد مقایسه شده است.

۲. پیش‌پردازش داده‌ها و آماده‌سازی برای آموزش

مراحل آماده‌سازی داده‌ها به شرح زیر انجام گرفت:
۱. مرتب‌سازی زمانی: ابتدا فایل داده‌های GLD بر اساس ستون تاریخ مرتب شد تا تقدم و تاخر روزهای معاملاتی حفظ شود.
۲. ساخت متغیر هدف: قیمت پایانی با یک گام شیفت زمانی به عقب (shift(-1)) به عنوان قیمت روز بعد (Close_Next) در نظر گرفته شد. سطر آخر به دلیل نامشخص بودن قیمت روز بعد از مجموعه حذف گردید و در نهایت ۱۷۶۰ سطر معتبر به دست آمد.
۳. مقیاس‌بندی ویژگی حجم: ستون Volume به دلیل داشتن مقادیر بسیار بزرگ (میلیونی) به مقیاس میلیون واحد تبدیل شد تا از خطای محاسباتی ماتریسی جلوگیری شود.
۴. تقسیم به داده‌های آموزش و آزمایش: برای رعایت ماهیت سری‌های زمانی، داده‌ها بدون جابجایی تصادفی (بدون Shuffle) تقسیم شدند؛ ۸۰ درصد داده‌های اولیه (۱۴۰۸ نمونه از اوایل ۲۰۱۸ تا مرداد ۱۴۰۲) برای آموزش مدل و ۲۰ درصد انتهایی (۳۵۲ نمونه از مرداد ۱۴۰۲ تا پایان ۲۰۲۴) برای ارزیابی مدل‌ها اختصاص داده شد.

۳. آموزش مدل‌ها و معیارهای ارزیابی

مدل‌های Linear Regression و Ridge Regression با استفاده از کتابخانه scikit-learn روی داده‌های آموزش برازش داده شدند و سپس قیمت‌های روز بعد برای داده‌های آزمون پیش‌بینی شدند. معیارهای مورد بررسی شامل میانگین قدرمطلق خطا (MAE)، ریشه میانگین مربعات خطا (RMSE) و ضریب تعیین (R2) هستند:

مدل رگرسیون	MAE (دلار)	RMSE (دلار)	ضریب تعیین (R^2)
Linear Regression	1.4745	1.9759	0.9938
Ridge Regression (alpha=1.0)	1.4745	1.9757	0.9938

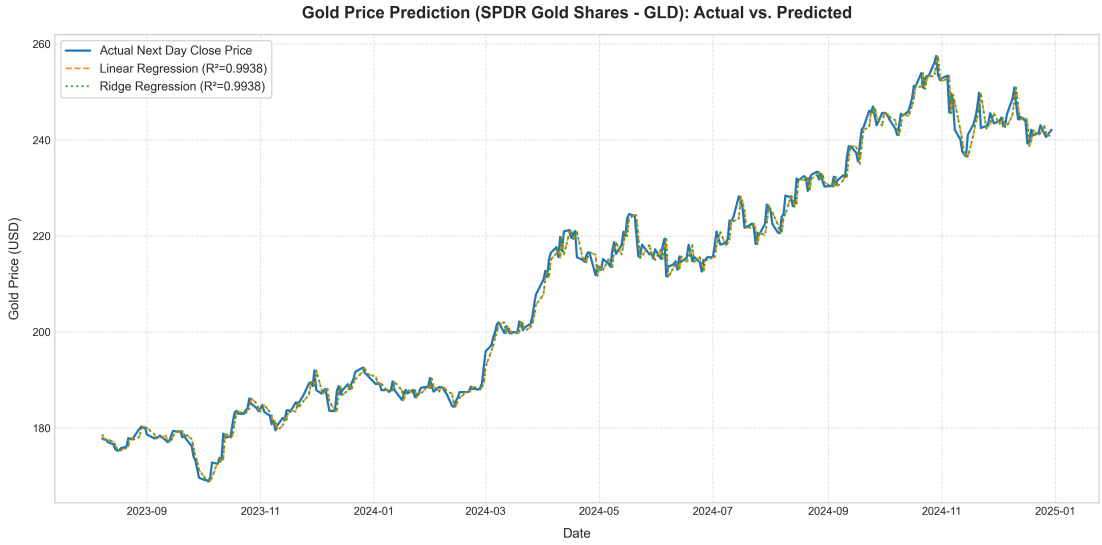
جدول ۲: مقایسه نمونه‌ای از قیمت واقعی روز بعد با پیش‌بینی دو مدل روی داده‌های تست:

تاریخ	قیمت واقعی (دلار)	پیش‌بینی Linear	پیش‌بینی Ridge
2024-12-16	243.94	244.80	244.80

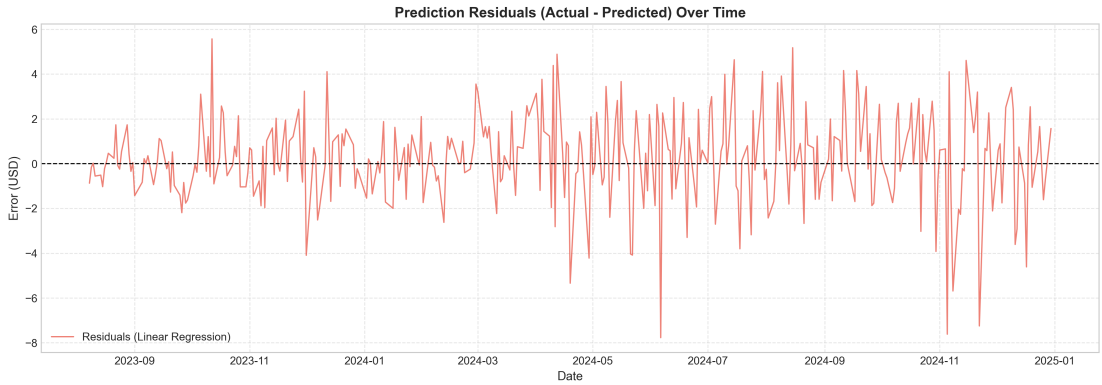
243.87	243.87	239.26	2024-12-17
238.78	238.77	239.60	2024-12-18
240.90	240.90	241.44	2024-12-23
240.56	240.56	242.13	2024-12-30

۴. نمودارهای خروجی و بررسی خطاها

نمودار مقایسه مقدار واقعی با مقادیر پیش‌بینی‌شده در شکل ۱ نمایش داده شده است:



شکل ۱: نمودار قیمت واقعی طلا در مقایسه با پیش‌بینی رگرسیون خطی و ریج (داده‌های تست)



شکل ۲: نمودار خطای پیش‌بینی (Residuals) در طول زمان

۵. نتیجه‌گیری و تحلیل نتایج

با توجه به نتایج حاصل، ضریب تعیین بالا (حدود ۰.۹۹۳۸) نشان می‌دهد قیمت پایانی روز جاری همبستگی خطی بسیار بالایی با قیمت روز بعد دارد. مدل ریج با اعمال جریمه L2 توانسته خطای RMSE را به مقدار کمی کاهش دهد (از ۱.۹۷۵۹ به ۱.۹۷۵۷ دلار) که نشان‌دهنده جلوگیری نسبی از وزن‌دهی نامتعادل به ویژگی‌ها است. بررسی خطاهای باقیمانده (Residuals) مشخص می‌کند

که مدل‌های رگرسیون خطی به عنوان یک مبنای سریع و خوب عمل می‌کنند اما توانایی پیش‌بینی شوک‌های ناگهانی بازار و روندهای غیرخطی شدید را ندارند.